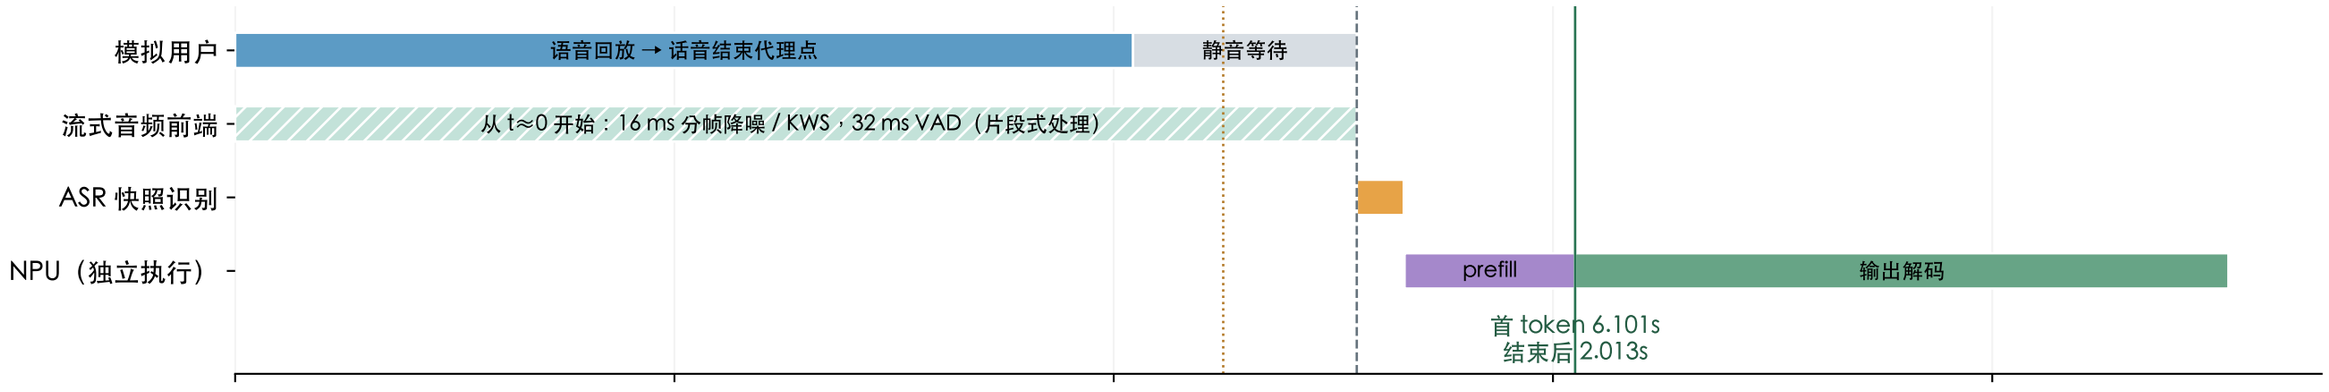
两阶段判停：把计算提前到静音确认期间

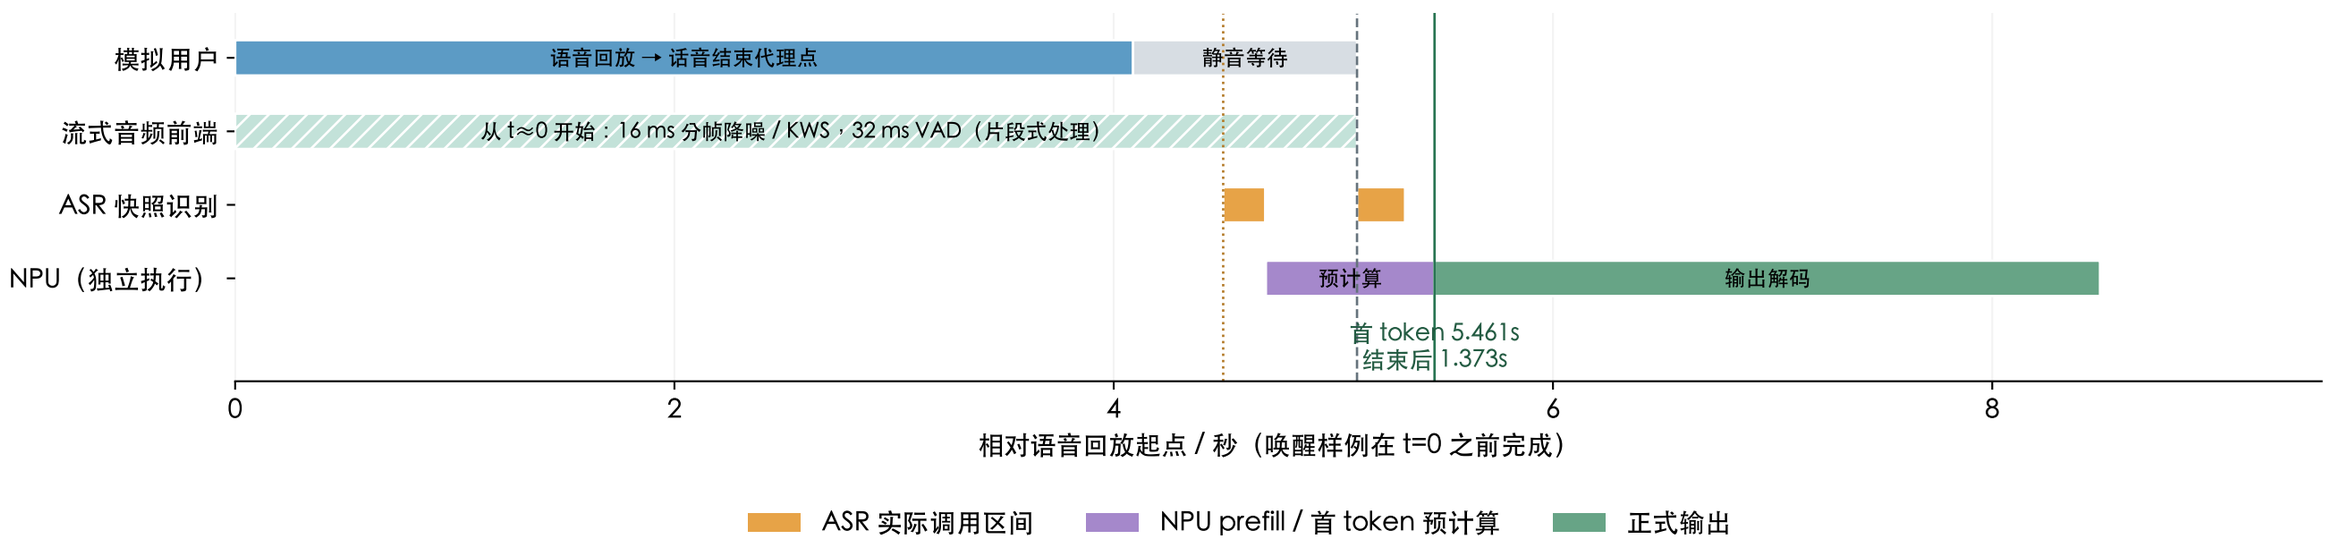
“我想泡一杯茶，你还记得我喜欢喝什么吗？” · 干净语音配对实测

GTCRN 降噪始终开启；Paraformer 整段快照识别；NPU 文本模型常驻、system KV 64 token

基线：确认结束后才开始 ASR / NPU



两阶段：0.4 s 静音时先算，1.0 s 静音时确认



前端长条表示持续接收、分帧处理的时间窗口，并非 CPU 全程满载。ASR 与 NPU 各行允许并行。

首 token 按首段非空解码文本计；话音结束为 VAD 样本代理点，未做人工声学标注。